

# **Steam Games Market Insights**

Predição e explicação de sucesso comercial estimado na Steam

Davi Silva de Melo Lins  
Iury Kauann David Nogueira  
Isabelle de Lima Xavier  
João Raphael Leão Guimarães Oliveira  
Marcelo Palmeira Falcão

Projeto Final de Ciência de Dados | 2026

# Problema, pergunta e decisão apoiada

## Problema de negócio

Ajudar desenvolvedores indie e publishers a priorizar decisões de produto, preço e posicionamento com base em evidências do mercado Steam.

## Pergunta de pesquisa

Quais características dos jogos publicados na Steam estão associadas a maior chance de sucesso comercial estimado?

## Decisão apoiada

Transformar dados históricos de jogos em um radar para levantar hipóteses de produto, mercado e comunicação, sem tratar o modelo como decisão automática.

A análise busca reduzir incerteza, não prometer uma fórmula de sucesso.

## Steam Games Dataset

- Fonte pública no Kaggle.
- 122.611 jogos processados.
- 49 colunas após engenharia.
- Variáveis numéricas, categóricas, listas e datas.

## Processo técnico

Limpeza, parsing de datas/listas, tratamento de nulos, transformação de owners e criação de features.

## Oportunidade

Converter histórico de preço, reviews, tags, recursos da Steam e engajamento em apoio à decisão.

A pasta dataset/ não é versionada; a reprodução exige baixar a base no Kaggle e rodar o pipeline localmente.

# Variável-alvo: success\_commercial

## Definição


Proxy binária de sucesso comercial estimado, **não receita real**.

**Critério:** top 30% do score composto por:

- owners estimados;
- total de reviews;
- peak CCU;
- recomendações;
- tempo médio de jogo.

Score com  $\log_{1p}$  + ranking percentual.

Vazamento removido: componentes do alvo e `positive_ratio`.




Classe positiva: aproximadamente 30% da base.

## Hipóteses avaliadas

- Multiplayer e recursos sociais.
- Estratégia pago vs. gratuito.
- Achievements e engajamento.
- Tags, gêneros e categorias.

## Resultados observados

- Multiplayer: 44,9% vs. 26,7%.
- Pagos: 33,4% vs. gratuitos: 17,6%.
- Testes: ( $p < 10^{-300}$ ).




## Leitura correta

Associação estatística no conjunto analisado, **não causalidade**.

# Modelagem, validação e melhor resultado

## Modelos avaliados

- Logistic Regression.
- Decision Tree.
- Random Forest.
- Extra Trees.
- HistGradientBoosting.



## Validação

- Split estratificado 80/20.
- Validação cruzada 3-fold.
- F1 e ROC-AUC como métricas centrais.

### Melhor modelo

#### HistGradientBoostingClassifier

F1 = 0,7395    ROC-AUC = 0,9155

Accuracy = 0,8285    Precision = 0,6793    Recall = 0,8115

Insights combinam EDA, testes estatísticos, modelagem e interpretabilidade.

## Produto social

Multiplayer está associado a maior taxa de sucesso estimado.

**Ação:** avaliar co-op, competitivo ou eventos online quando fizer sentido ao gênero.

## Preço

Gratuito não apresentou maior sucesso estimado no conjunto analisado.

**Ação:** testar preço baixo, demo ou promoção sem depender automaticamente de free-to-play.

## Engajamento

Achievements aparecem associados a maior taxa de sucesso estimado.

**Ação:** conectar conquistas a progresso real de gameplay.

Avaliar sucesso por reviews, peak CCU, retenção, conversão e tempo médio após o lançamento.

# Recurso extra: app Streamlit/Gemini

## App local

- Carrega `games.csv` ou CSV compatível.
- Permite seleccionar modelos.
- Exibe métricas e gráficos.
- Reutiliza alvo e cuidados contra vazamento.

## Gemini opcional

Relatório automatizado via `.env`; o app funciona sem chave e envia apenas resumo agregado.

## Papel do recurso


Artefato auxiliar de comunicação e demonstração local, não fonte principal da análise.

# Decisão recomendada e limitações

## Decisão apoiada

Priorizar hipóteses de produto, preço e posicionamento com evidências do modelo e análise humana.

- Modelo como triagem, não decisão automática.
- FP/FN servem como alertas para análise humana.
- Proxy, não receita real.
- Variáveis pós-lançamento limitam uso pré-lançamento.
- Associação não implica causalidade.



Features relevantes: tags, idade, trading cards, preço e desconto.

# Obrigado!

Perguntas?

Steam Games Market Insights | Projeto Final de Ciência de Dados