

Steam Games Market Insights

Predição e explicação de sucesso comercial estimado na Steam

Davi Silva de Melo Lins
Iury Kauann David Nogueira
Isabelle de Lima Xavier
João Raphael Leão Guimarães Oliveira
Marcelo Palmeira Falcão

Projeto Final de Ciência de Dados | 2026

Abordagem comercial

Valor do projeto para decisão de negócio

Foco desta parte

Problema, oportunidade, principais evidências e recomendações para desenvolvedores indie e publishers.

Problema e oportunidade

Problema de negócio

Desenvolvedores indie e publishers precisam decidir produto, preço e posicionamento em um mercado com muita competição e visibilidade desigual.

Pergunta de negócio

Quais características dos jogos publicados na Steam estão associadas a maior chance de sucesso comercial estimado?

Solução proposta

Usar dados históricos da Steam como um radar para priorizar hipóteses de produto, mercado e comunicação.


O objetivo não é prometer uma fórmula de sucesso, mas reduzir incerteza antes de decisões de produto e lançamento.

Evidências principais

O que apareceu com mais força

- Multiplayer: 44,9% vs. 26,7%.
- Jogos pagos: 33,4% vs. gratuitos: 17,6%.
- Achievements: 40,1% vs. 19,3%.

Esses números não dizem que uma característica causa sucesso. Eles indicam padrões observados na base.



Leitura para negócio

Os dados ajudam a escolher quais hipóteses testar primeiro: produto social, preço e engajamento.

Transformamos resultados técnicos em recomendações práticas.

Produto social

Multiplayer aparece associado a maior taxa de sucesso estimado.

Ação: avaliar co-op, competitivo ou eventos online quando fizer sentido ao gênero.

Preço

Gratuito não apresentou maior sucesso estimado no conjunto analisado.

Ação: testar preço baixo, demo ou promoção sem depender automaticamente de free-to-play.

Engajamento

Achievements aparecem associados a maior taxa de sucesso estimado.

Ação: conectar conquistas a progresso real de gameplay.

Avaliar sucesso por reviews, peak CCU, retenção, conversão e tempo médio após o lançamento.

Fechamento do pitch

Como usar o projeto

Usar o modelo como um radar: ele aponta sinais de oportunidade, mas a decisão final ainda depende de gênero, público, orçamento e estratégia comercial.

Na prática

- Priorizar hipóteses de produto.
- Discutir preço e posicionamento.
- Comparar jogos por sinais históricos.
- Apoiar conversas com banca, gestor ou publisher.

Cuidados

- O alvo é uma proxy, não receita real.
- O modelo não garante sucesso.
- Os padrões são associações.
- A análise humana continua essencial.

Seção Técnica

Base, metodologia, modelos, métricas e limitações

Foco desta parte

Como a análise foi construída: dados, variável-alvo, prevenção de vazamento, inferência, modelagem e avaliação.

Steam Games Dataset

- Fonte pública no Kaggle.
- 122.611 jogos processados.
- 49 colunas após limpeza e engenharia.
- Variáveis numéricas, categóricas, listas e datas.

Preparação

Limpeza, parsing de datas/listas, tratamento de nulos, transformação de owners e criação de features.

Features derivadas

Idade do jogo, preço, desconto, contagens de tags/gêneros/categorias, idiomas e flags de recursos da Steam.

A pasta dataset/ não é versionada; a reprodução exige baixar a base no Kaggle e rodar o pipeline localmente.

Variável-alvo e vazamento


`success_commercial`

Proxy binária de sucesso comercial estimado, **não receita real**.

Critério: top 30% do score composto por:

- owners estimados;
- total de reviews;
- peak CCU;
- recomendações;
- tempo médio de jogo.

O score usa $\log_{1p}$ + ranking percentual para reduzir o peso de valores extremos.



Prevenção de vazamento

Removemos do treino as variáveis usadas para criar o alvo, o score composto e a razão de reviews positivas.

Hipóteses avaliadas

- Multiplayer e recursos sociais.
- Estratégia pago vs. gratuito.
- Achievements e engajamento.
- Tags, gêneros e categorias.

Testes utilizados

- Mann–Whitney.
- Qui-quadrado.
- Resultados com ($p < 10^{-300}$).



Interpretação

Os testes reforçam associação estatística, mas não provam causa e efeito.

Tipo do problema

- Classificação binária supervisionada.
- Classe positiva: sucesso estimado.

Modelos avaliados

- Logistic Regression e Decision Tree.
- Random Forest e Extra Trees.
- HistGradientBoostingClassifier.


Validação

- Split treino/teste estratificado 80/20.
- Validação cruzada estratificada 3-fold.
- Semente fixa: 42.

Por que não só accuracy?

A classe positiva tem cerca de 30%; por isso, F1 e ROC-AUC são métricas centrais.

Resultados e melhor modelo



Melhor modelo

HistGradientBoostingClassifier $F1 = 0,7395$
 $ROC-AUC = 0,9155$ $Accuracy = 0,8285$
 $Precision = 0,6793$ $Recall = 0,8115$

A Random Forest teve accuracy e precision ligeiramente maiores, mas o HistGradientBoosting apresentou melhor F1 e ROC-AUC.


Interpretação e limitações

Análise de erros

- Falsos positivos: expectativa excessiva.
- Falsos negativos: oportunidades ignoradas.
- O modelo deve apoiar análise, não automatizar decisões.

Limitações

- Proxy, não receita real.
- Variáveis pós-lançamento.
- Associação não implica causalidade.



Sinais relevantes no modelo: tags, idade, trading cards, preço e desconto.

Recurso extra: app Streamlit/Gemini

App local

- Carrega `games.csv` ou CSV compatível.
- Permite selecionar modelos.
- Exibe métricas e gráficos.
- Demonstra o pipeline de forma interativa.

Gemini opcional

Relatório automatizado com Gemini. A API key fica no `.env`; sem chave, o app continua funcionando, apenas sem relatório LLM.

Papel do recurso

Artefato auxiliar para comunicação e demonstração local; não substitui o relatório técnico nem a análise principal.

Obrigado!

Perguntas?

Steam Games Market Insights | Projeto Final de Ciência de Dados